analise_de_hiperparametro

May 29, 2024

1 Busca de Índice e Consulta de documento

Autor: Davi J. Leite Santos

Versão: 0.0.3

Data: 25 de Abril de 2024

Localização: Ribeirão das Neves, Minas Gerais - Brasil

1.1 Contato

• Endereço: Ribeirão das Neves, Minas Gerais - Brasil

Email: davi.jls@outlook.com
 LinkedIn: davi-j-leite-santos
 Website: davijls.com.br

1.2 Principais Competências

- Cibersegurança
- Segurança da Informação
- Operações de TI

```
[]: import json
import re
import os
import time
import nltk
from nltk.stem import RSLPStemmer
```

```
[]: # Baixar os recursos necessários do NLTK

nltk.download('rslp')

nltk.download('punkt')

# Inicializar o Stemmer para português

stemmer = RSLPStemmer()
```

```
[nltk_data] C:\Users\davim\AppData\Roaming\nltk_data...
[nltk_data] Package punkt is already up-to-date!
```

2 Funções de criação de chunk para a analise de granularidade

```
[]: # Função para carregar o índice e o vocabulário
     def load_index(index_file, vocab_file):
         with open(index_file, 'r', encoding='utf-8') as f:
             index = json.load(f)
         with open(vocab_file, 'r', encoding='utf-8') as f:
             vocab = json.load(f)
         return index, vocab
[]: # Função para criar chunks de um documento
     def create_chunks(text, chunk_size):
         words = text.split()
         return [' '.join(words[i:i + chunk_size]) for i in range(0, len(words),
      ⇔chunk_size)]
[]: # Função para buscar termos no índice
     def search_term(index, vocab, term):
         stemmed term = stemmer.stem(term)
         if stemmed_term in vocab:
             word id = vocab[stemmed term]
             if str(word_id) in index:
                return index[str(word id)]
         return {}
[]: # Função para salvar o progresso em um arquivo
     def save_progress(progress_file, progress):
         with open(progress_file, 'w', encoding='utf-8') as f:
             f.write("Progress:\n")
             for key, value in progress.items():
                 f.write(f"{key}: {value}\n")
[]: # Função para carregar o índice e o vocabulário
     def load_index(index_file, vocab_file):
         with open(index_file, 'r', encoding='utf-8') as f:
             index = json.load(f)
         with open(vocab_file, 'r', encoding='utf-8') as f:
             vocab = json.load(f)
         return index, vocab
[]: # Função para simular a criação de arquivos de índice e vocabulário
     def create_temp_files(index_file, vocab_file, chunk_size):
         # Criar dados fictícios para o índice e vocabulário
         index_data = {f'word{chunk_size}': [chunk_size, chunk_size+1]}
```

```
vocab_data = {f'word{chunk_size}': chunk_size}

# Salvar dados fictícios nos arquivos
with open(index_file, 'w', encoding='utf-8') as f:
    json.dump(index_data, f)
with open(vocab_file, 'w', encoding='utf-8') as f:
    json.dump(vocab_data, f)
```

```
[]: # Função para processar arquivo com granularidade ajustável
     def process_file(file_path, chunk_size, doc_id, vocab, index):
         if not os.path.exists(file path):
             print(f"Arquivo n\u00e3o encontrado: {file_path}")
         with open(file_path, 'r', encoding='utf-8') as f:
             text = f.read()
         chunks = create_chunks(text, chunk_size)
         for chunk_id, chunk in enumerate(chunks):
             tokens = nltk.word_tokenize(chunk, language='portuguese')
             for pos, token in enumerate(tokens):
                 stemmed_token = stemmer.stem(token)
                 if stemmed_token not in vocab:
                     vocab[stemmed token] = len(vocab)
                 word_id = vocab[stemmed_token]
                 if word id not in index:
                     index[word_id] = {}
                 if doc id not in index[word id]:
                     index[word_id] [doc_id] = []
                 index[word_id][doc_id].append((chunk_id, pos))
```

```
[]: def create_inverted_index_with_chunks(files, chunk_size):
         index = {}
         vocab = \{\}
         vocab_id = 0
         doc_id = 0
         for file_path in files:
             with open(file_path, 'r', encoding='utf-8') as f:
                 words = f.read().split()
             chunk id = 0
             while chunk_id * chunk_size < len(words):</pre>
                 chunk = words[chunk_id * chunk_size:(chunk_id + 1) * chunk_size]
                 for pos, word in enumerate(chunk):
                     if word not in vocab:
                          vocab[word] = vocab_id
                          vocab_id += 1
                     term_id = vocab[word]
```

```
[]: # Função para simular a medição do tempo de busca com diferentes tamanhos de___
chunk

def measure_search_time_with_different_chunk_sizes(index, vocab, search_terms):
    total_search_time = 0.0
    num_searches = len(search_terms)
    for term in search_terms:
        start_time = time.time()
        _ = index.get(term, [])
        total_search_time += time.time() - start_time

avg_search_time = total_search_time / num_searches
    return avg_search_time
```

```
[]: # Função para simular a indexação de documentos com diferentes tamanhos de chunk
     def index_documents_with_different_chunk_sizes(files_dir, chunk_sizes):
         index_file, vocab_file = files_dir
         index, vocab = load_index(index_file, vocab_file)
         results = []
         for chunk_size in chunk_sizes:
             chunked_index = {k: v[:chunk_size] if isinstance(v, list) else v for k,_
      →v in index.items()}
             chunked_vocab = {k: v for k, v in vocab.items() if len(k) <= chunk_size}</pre>
             index_size = len(json.dumps(chunked_index).encode('utf-8'))
             vocab_size = len(json.dumps(chunked_vocab).encode('utf-8'))
             total_size = index_size + vocab_size
             results.append({
                 'chunk_size': chunk_size,
                 'index': chunked_index,
                 'vocab': chunked_vocab,
                 'index_size': index_size,
                 'vocab_size': vocab_size,
                 'total_size': total_size,
             })
         return results
```

```
[]: # Função principal para realizar a análise de hiperparâmetros
    def analyze_hyperparameters(files_dir, search_terms, chunk_sizes, output_file,_
      →progress_file):
        results = index documents with different chunk sizes(files dir, chunk sizes)
        with open(output_file, 'w', encoding='utf-8') as f_output,_
      →open(progress_file, 'w', encoding='utf-8') as f_progress:
            for result in results:
                avg_search_time =
      →result['vocab'], search_terms)
                result['avg_search_time'] = avg_search_time
                f_output.write(f"Chunk Size: {result['chunk_size']}\n")
                f_output.write(f"Index Size: {result['index_size']} bytes\n")
                f_output.write(f"Vocab Size: {result['vocab_size']} bytes\n")
                f_output.write(f"Total Size: {result['total_size']} bytes\n")
                f_output.write(f"Average Search Time: {result['avg_search_time']:.

off segundos\n")
                f_output.write("\n")
                f_progress.write(json.dumps(result) + "\n")
                f_output.flush()
                f_progress.flush()
[]: # Definir os parâmetros
    files_dir = ('index_geral.json', 'vocab_geral.json')
    search_terms = ['educação', 'linguagem', 'noticia', 'ideia', 'politica']
    chunk_sizes = [50, 100, 200, 500] # Tamanhos de chunks para testar
    output_file = 'hyperparameter_analysis.txt'
    progress_file = 'hyperparametro_progress.txt'
[]: analyze_hyperparameters(files_dir, search_terms, chunk_sizes, output_file,__
      →progress_file)
[]:
[]:
```